

Санкт-Петербургский государственный университет
Кафедра моделирования экономических систем

Кирюшин Николай Дмитриевич

Выпускная квалификационная работа бакалавра

**Выявление информативных спектральных
каналов для обнаружения магния по данным
дистанционного зондирования Земли**

Направление 01.03.02

Прикладная математика и информатика

Научный руководитель,
доктор физ.-мат. наук,
профессор
Панкратова Я. Б.

Санкт-Петербург

2025

Содержание

Введение	3
Постановка задачи	6
Обзор литературы	9
1 Глава 1. Теоретическая часть	12
1.1. Формальная постановка задачи	12
1.2. Описание данных	13
1.3. Предобработка данных	13
1.4. Многоклассовая классификация	13
1.5. Инструменты и алгоритмы	14
1.6. Оценка качества	14
2 Глава 2. Модели машинного обучения для задачи классификации	15
2.1. Логистическая регрессия	15
2.2. Физически обоснованные регуляризации	15
2.3. Формальное описание модели CatBoost	18
Обучение деревьев	20
Симметричные деревья	20
Регуляризация в CatBoost	20
Алгоритм обучения	21
Гиперпараметры	21
2.4. Метод снижения размерности PCA	21
Обоснование применения PCA	21
Обоснованность подхода	23
Модель классификации	24
Корректность подхода	24

3	Глава 3: Математическая модель для наблюдаемых спектральных распределений	25
3.1.	Формализованная модель	25
	Компоненты модели:	26
3.2.	Особенности для разных типов образцов	27
3.3.	Полная модель	27
3.4.	Практическая реализация	28
4	Глава 4. Результаты.	29
4.1.	Результаты логистической регрессии.	29
	Результаты экспериментов	29
	Метрики качества на тестовой выборке	30
	Значимые спектральные диапазоны	30
	Интерпретация и анализ обучения логистической регрессии .	31
4.2.	Градиентный бустинг	33
	Результаты	33
	Выводы	34
4.3.	РСА	35
	Код и результаты	35
	Выводы	38
	Заключение	39

Введение

Сельское хозяйство является одной из ключевых отраслей экономики, обеспечивающей продовольственную безопасность населения. Эффективность сельскохозяйственного производства напрямую зависит от множества факторов, среди которых важнейшее место занимает обеспеченность растений необходимыми питательными элементами. Магний (Mg) играет критическую роль в жизни растений, прежде всего как центральный атом молекулы хлорофилла, отвечающий за процесс фотосинтеза [19]. Кроме того, магний участвует во множестве ферментативных реакций, транспорте ассимилятов и синтезе белков [16]. Недостаток или избыток магния в растении может существенно снижать урожайность и качество сельскохозяйственной продукции, в частности, пшеницы. Оценка содержания магния непосредственно в тканях растений является важным инструментом для диагностики их минерального питания.

Традиционно оценка содержания питательных элементов, включая магний, в растениях проводится методами химического анализа растительных образцов в лабораторных условиях. Обычно это включает озоление (сухое или мокрое) образца с последующим определением концентрации магния методами атомно-абсорбционной спектрометрии (ААС) или масс-спектрометрии с индуктивно связанной плазмой (ИСП-МС) [17]. Несмотря на свою точность, эти методы имеют ряд существенных недостатков: они трудоемки, требуют значительных временных и финансовых затрат, связаны с отбором, транспортировкой и сложной пробоподготовкой, а также носят разрушающий характер по отношению к образцу. Это затрудняет оперативный мониторинг состояния посевов на больших площадях.

В последние годы активно развиваются альтернативные, неинвазивные методы оценки состояния растений, основанные на анализе их спектральных характеристик. Спектральный анализ, в частности анализ интенсивности отраженного света в различных диапазонах длин волн (спектроскопия отражения), позволяет получать информацию о биохимическом составе и физиологическом состоянии растений без прямого контакта и разрушения образца [1; 5]. Предполагается, что различные компоненты растительных тканей (пигменты, вода, структурные углеводы, белки), содержание и состояние которых зависит от уровня обеспеченности питательными элементами, по-разному взаимодействуют со светом. Это отражается в уникальных спектральных "сигнатурах" растений. Возникает гипотеза о возможности использования этих спектральных данных для косвенной оценки содержания химических элементов в растениях, в том числе магния, через его влияние на содержание хлорофилла и другие физиологические параметры [13].

Актуальность данной работы обусловлена необходимостью разработки экспрессных, экономически эффективных и неразрушающих методов мониторинга минерального питания сельскохозяйственных культур, в частности пшеницы, для нужд точного земледелия. Возможность быстрой оценки содержания магния в растениях на основе их спектральных характеристик (полученных с помощью полевых спектрометров или систем дистанционного зондирования) позволит оптимизировать стратегии внесения удобрений (например, для некорневых подкормок), прогнозировать урожайность и качество продукции, снизить затраты и уменьшить негативное воздействие на окружающую среду. Разработка таких методов является важным шагом к созданию интеллектуальных систем

управления агропроизводством.

Целью данной выпускной квалификационной работы является исследование возможности определения уровня содержания магния в растениях пшеницы на основе анализа их спектральных характеристик с использованием методов машинного обучения.

Постановка задачи

Исходя из актуальности и цели работы, необходимо решить следующие **задачи**:

1. **Проанализировать существующие методы** определения содержания магния в растениях, выявить их преимущества и недостатки, уделив особое внимание традиционным химическим методам анализа растительных тканей и современным спектральным подходам (включая дистанционное зондирование).
2. **Подготовить и проанализировать данные:** Использовать набор данных, содержащий спектральные характеристики образцов или посевов пшеницы (интенсивность отраженного света по ~ 300 длинам волн) и соответствующие им классы содержания магния в растительных тканях (например, "mg0— низкое, "mg12— среднее/достаточное, "mg24— высокое, определенные по результатам химического анализа). Провести предварительный анализ данных для выявления потенциальных зависимостей между спектральными характеристиками и содержанием магния.
3. **Разработать и обучить модели машинного обучения** для решения задачи классификации образцов пшеницы по уровню содержания магния на основе их спектральных данных. В качестве основных методов рассмотреть:
 - Логистическую регрессию, уделив внимание разработке и применению кастомной регуляризации для возможного отбора наиболее информативных длин волн или учета специфики спек-

тральных данных (например, мультиколлинеарности).

- Методы, основанные на деревьях решений (например, Случайный лес, Градиентный бустинг), известные своей эффективностью в задачах классификации со сложными нелинейными зависимостями, характерными для биологических систем [2].

4. **Оценить качество разработанных моделей** с использованием подходящих метрик (например, точность, полнота, F1-мера, AUC-ROC) и методов кросс-валидации для обеспечения надежности результатов.
5. **Сравнить эффективность различных моделей** и подходов к регуляризации. Проанализировать, какие участки спектра (длины волн) вносят наибольший вклад в классификацию содержания магния в пшенице, и попытаться связать их с известными спектральными особенностями растительности (например, поглощением хлорофилла, влиянием водного статуса).
6. **Сделать выводы** о принципиальной возможности и практической применимости использования спектрального анализа и машинного обучения для экспресс-оценки содержания магния в растениях пшеницы как альтернативы или дополнения к традиционным химическим методам.

Объект исследования: Процесс взаимосвязи спектральных характеристик отражения растений пшеницы и содержания в них магния.

Предмет исследования: Методы машинного обучения для класси-

фикации образцов пшеницы по уровню содержания магния на основе данных спектрального анализа.

Обзор литературы

Традиционные методы анализа магния в растениях и их ограничения Классические подходы к определению магния в растительных тканях включают отбор репрезентативных образцов (листьев, целых растений), их высушивание, измельчение и последующее химическое определение элемента. Чаще всего используется метод сухого озоления или мокрой минерализации с последующим анализом экстракта на атомно-абсорбционных спектрометрах (ААС) или методом ИСП [12]. Эти методы обеспечивают высокую точность, но являются разрушающими, требуют значительных временных и ресурсных затрат, специального лабораторного оборудования и квалифицированного персонала. Это существенно ограничивает их применение для оперативного мониторинга состояния посевов в реальном времени и для задач точного земледелия, требующих пространственно-распределенной информации [14].

Спектральные методы как альтернатива для оценки состояния растений Спектральный анализ, основанный на измерении отраженного или пропущенного света в видимом (VIS), ближнем инфракрасном (NIR) и коротковолновом инфракрасном (SWIR) диапазонах, позволяет неинвазивно оценивать биохимический состав и физиологическое состояние растений [22; 24]. Содержание магния напрямую связано с концентрацией хлорофилла, который имеет характерные особенности поглощения в синей и красной областях спектра [10]. Кроме того, дефицит магния может вызывать изменения в структуре листа и содержании воды, что также находит отражение в спектральных характеристиках, особенно в NIR и SWIR диапазонах [21]. Исследования показывают наличие корреляций между спектральными индексами или полными спек-

трами отражения и содержанием различных макро- и микроэлементов в растениях, хотя часто эти связи являются косвенными и сложными [7; 8]. Использование гиперспектральных данных (с большим количеством узких спектральных каналов, как ~ 300 длин волн в данном исследовании) потенциально позволяет выявлять тонкие спектральные особенности, связанные с содержанием конкретных элементов, таких как магний [4].

Применение машинного обучения в спектральном анализе растений Интерпретация сложных гиперспектральных данных для оценки содержания химических элементов требует применения мощных статистических методов и алгоритмов машинного обучения. Алгоритмы классификации, такие как логистическая регрессия с методами регуляризации (например, LASSO, Ridge) для отбора признаков и борьбы с мультиколлинеарностью [23], и ансамблевые методы на основе деревьев решений (Random Forest, Gradient Boosting) [2; 9], активно используются для анализа спектральных данных в сельском хозяйстве и экологии [15]. В работах, подобных Grechuk et al. (2020) [11], демонстрируются подходы к работе с мультиколлинеарностью в данных высокой размерности, что характерно для спектрометрии. Методы градиентного бустинга, такие как CatBoost, показали свою эффективность при работе с разнородными признаками и сложными зависимостями [3], что может быть полезно при учете не только спектральных данных, но и других факторов.

Перспективные направления Современные исследования фокусируются на разработке робастных моделей, способных работать в различных условиях (фазы роста растений, погодные условия, сортовые особенности). Активно исследуется применение методов глубокого обуче-

ния (например, сверточных нейронных сетей) для автоматического извлечения информативных признаков из спектральных кривых [6]. Также перспективным является совместное использование данных с различных сенсоров (гиперспектральных, тепловых, лидаров) и интеграция спектральной информации с моделями роста культур для более точного прогнозирования и управления производственным процессом [18]. Работа Sidorov & Zolotykh (2020) [20], хотя и рассматривает общие вопросы делимости данных, подчеркивает важность анализа структуры данных в многомерном пространстве признаков, что актуально и для спектральных данных растений.

1 Глава 1. Теоретическая часть

1.1. Формальная постановка задачи

Задача относится к категории **многоклассовой классификации**, где каждый объект (набор спектральных характеристик образца растения) должен быть отнесён к одному из трёх классов уровня содержания магния в растительных тканях:

- mg0: дефицит магния (соответствует низкому уровню, например, около 0 мг/кг),
- mg12: нормативное содержание (соответствует среднему/достаточному уровню, например, около 12 мг/кг),
- mg24: избыток (соответствует высокому уровню, например, около 24 мг/кг).

(Примечание: Точные пороговые значения концентраций для классов mg0, mg12, mg24 определены по результатам химического анализа экспериментальных данных.)

Математически задача формулируется как поиск функции $f : X \rightarrow \mathcal{Y}$, где:

- $X \in \mathbb{R}^{n \times d}$ — матрица признаков, содержащая спектральные измерения для всех образцов. Здесь $n = 300$ — число образцов, $d = 300$ — число спектральных каналов (длин волн). Каждый образец представлен вектором признаков $\mathbf{x}_i \in \mathbb{R}^d$.
- $\mathcal{Y} = \{\text{mg0}, \text{mg12}, \text{mg24}\}$ — множество меток классов. В процессе обучения и оценки для удобства могут использоваться числовые метки, соответствующие этим классам (например, 0, 1, 2 или 0, 12, 24).

Целью является построение модели f , которая минимизирует ошибку классификации на независимой тестовой выборке.

1.2. Описание данных

Исходный датасет содержит:

- **300 образцов растений**, каждый представлен **300 спектральными измерениями** интенсивности отражения в диапазоне 390,04–1031,23 нм.
- Распределение выборок:
 - Тренировочная выборка: 240 объектов (80%),
 - Тестовая выборка: 60 объектов (20%).

1.3. Предобработка данных

Для устранения масштабных различий между признаками выполнена **стандартизация**:

$$z = \frac{x - \mu}{\sigma}, \quad (1)$$

где μ — среднее значение, σ — стандартное отклонение.

1.4. Многоклассовая классификация

Многоклассовая классификация — задача машинного обучения, где объект относится к одному из трёх или более взаимоисключающих классов. Основные подходы:

- Алгоритмы с естественной поддержкой многоклассовости (например, деревья решений),

- Стратегии «один против всех» (*One-vs-Rest*) или «один против одного» (*One-vs-One*).

1.5. Инструменты и алгоритмы

- Библиотеки Python:

- `pandas`, `numpy` — обработка табличных данных,
- `sklearn` — реализация алгоритмов ML,
- `torch` — нейронные сети,
- `matplotlib` — визуализация.

- Методы классификации:

- Логистическая регрессия,
- Ансамблевые алгоритмы (Random Forest, Gradient Boosting),

1.6. Оценка качества

Для валидации моделей применялись метрики:

- **Accuracy** (доля верных предсказаний):

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}, \quad (2)$$

- **F1-score** (средневзвешенный по классам):

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (3)$$

2 Глава 2. Модели машинного обучения для задачи классификации

2.1. Логистическая регрессия

Многоклассовая логистическая регрессия Для многоклассовой классификации используется обобщённая логистическая регрессия с функцией softmax. Вероятность отнесения объекта $\mathbf{x}$ к классу k задаётся как:

$$P(y = k|\mathbf{x}; \mathbf{W}) = \frac{\exp(\mathbf{w}_k^T \mathbf{x})}{\sum_{l=1}^c \exp(\mathbf{w}_l^T \mathbf{x})}, \quad (4)$$

где:

- $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_c]^T \in \mathbb{R}^{c \times d}$ — матрица весов,
- $c = 3$ — число классов ($\mathcal{Y} = \{0, 12, 24\}$),
- Классификатор выбирает класс с максимальной уверенностью: $\hat{y} = \arg \max_k P(y = k|\mathbf{x})$.

2.2. Физически обоснованные регуляризации

На основе спектральных особенностей магния введены два типа регуляризации:

Математический смысл регуляризации гладкости

Пусть $\mathbf{w}_k = (w_{k,1}, w_{k,2}, \dots, w_{k,d})^T$ — вектор весов для класса k , где $d = 300$ — количество спектральных признаков. Матрица соседства $\mathbf{N} \in \{0, 1\}^{d \times d}$ формализует топологию спектральных измерений:

$$N_{i,j} = \begin{cases} 1, & \text{если } j = i - 1 \text{ или } j = i + 1 \text{ для } 2 \leq i \leq d - 1, \\ 1, & \text{если } (i = 1 \text{ и } j = 2) \text{ или } (i = d \text{ и } j = d - 1), \\ 0, & \text{иначе.} \end{cases} \quad (5)$$

Регуляризация R_{smooth} штрафует отклонение веса $w_{k,j}$ от **среднего значения его соседей**:

$$R_{\text{smooth}}(\mathbf{W}) = \lambda_{\text{smooth}} \sum_{k=1}^c \sum_{j=1}^d \left(w_{k,j} - \frac{1}{\deg(j)} \sum_{l \in \mathcal{N}(j)} w_{k,l} \right)^2, \quad (6)$$

где: - $\deg(j) = \sum_{l=1}^d N_{j,l}$ — степень вершины j (число соседей), - $\mathcal{N}(j) = \{l \mid N_{j,l} = 1\}$ — множество соседей j -й длины волны.

Для внутренних точек ($2 \leq j \leq d - 1$):

$$\deg(j) = 2, \quad \mathcal{N}(j) = \{j - 1, j + 1\}, \quad (7)$$

для крайних точек:

$$\deg(1) = \deg(d) = 1, \quad \mathcal{N}(1) = \{2\}, \quad \mathcal{N}(d) = \{d - 1\}. \quad (8)$$

Дискретный аналог оператора Лапласа Регуляризация аппроксимирует **дискретную вторую производную** весов вдоль спектра:

$$\frac{\partial^2 w_{k,j}}{\partial \lambda^2} \approx \frac{w_{k,j+1} - 2w_{k,j} + w_{k,j-1}}{(\Delta \lambda)^2}, \quad (9)$$

где $\Delta \lambda$ — шаг между длинами волн. При $\Delta \lambda = 1$:

$$R_{\text{smooth}} \propto \sum_{j=2}^{d-1} \left(\frac{\partial^2 w_{k,j}}{\partial \lambda^2} \right)^2 + \text{краевые члены}. \quad (10)$$

Оптимизационные свойства Минимизация R_{smooth} приводит к выполнению **условия гармоничности**:

$$w_{k,j} = \frac{1}{\deg(j)} \sum_{l \in \mathcal{N}(j)} w_{k,l} \quad \forall j. \quad (11)$$

Это означает, что вес каждой длины волны стремится к среднему значению своих соседей, что:

- + Гарантирует гладкость весовой функции вдоль спектра.
- + Подавляет высокочастотные колебания (шумовые пики).
- Может подавить узкие, но физически значимые спектральные линии.

Градиент регуляризации Для оптимизации методом градиентного спуска:

$$\frac{\partial R_{\text{smooth}}}{\partial w_{k,j}} = 2\lambda_{\text{smooth}} \left(w_{k,j} - \frac{1}{\deg(j)} \sum_{l \in \mathcal{N}(j)} w_{k,l} \right). \quad (12)$$

Градиент "тянет" $w_{k,j}$ к локальному среднему соседей, обеспечивая сглаживание.

Сравнение с классической L_2 -регуляризацией

- **Сходство:** Обе штрафуют большие значения весов.
- **Различие:** - L_2 : $\sum w_{k,j}^2 \rightarrow$ глобальное подавление весов. - R_{smooth} : $\sum (w_{k,j} - \text{соседи})^2 \rightarrow$ локальное согласование весов.

Регуляризация группировки (Group Penalty) Штрафует совместную активацию далёких спектральных признаков:

$$R_{\text{group}}(\mathbf{W}) = \lambda_{\text{group}} \sum_{k=1}^c \sum_{j=1}^d \sum_{l=1}^d |w_{k,j}| \cdot D_{j,l} \cdot |w_{k,l}|, \quad (13)$$

где $D_{j,l} = |\lambda_j - \lambda_l|$ — расстояние между длинами волн.

Свойства:

- + Учитывает, что значимые для магния длины волн образуют компактные группы в спектре.

- + Подавляет шумовые корреляции между несвязанными участками спектра.
- Вычислительно сложная ($O(d^2)$ операций), требует оптимизации.

Комбинированная функция потерь Общая функция потерь с регуляризацией:

$$\mathcal{L}(\mathbf{W}) = \underbrace{-\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^c y_{ik} \log P(y = k | \mathbf{x}_i)}_{\text{Кросс-энтропия}} + \underbrace{R_{\text{smooth}}(\mathbf{W}) + R_{\text{group}}(\mathbf{W})}_{\text{Регуляризация}}. \quad (14)$$

Теоретические аспекты

- **Выпуклость:** Кросс-энтропия выпукла по $\mathbf{W}$, но R_{group} нарушает выпуклость из-за модулей.
- **Интерпретируемость:** Гладкость весов позволяет визуализировать значимые спектральные диапазоны.
- **Вычислительная сложность:** Градиент R_{group} требует вычисления $\frac{\partial}{\partial w_{k,j}}(|w_{k,j}| \cdot D_{j,l} \cdot |w_{k,l}|)$, что усложняет оптимизацию.

Практические ограничения

- При $\lambda_{\text{smooth}} \gg 1$ модель становится излишне гладкой и теряет чувствительность к узким спектральным линиям.
- Выбор λ_{group} требует перекрёстной проверки из-за невыпуклости целевой функции.

2.3. Формальное описание модели CatBoost

Постановка задачи Пусть задана обучающая выборка $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$,

где:

- $\mathbf{x}_i \in \mathbb{R}^d$ – вектор спектральных признаков ($d = 300$),
- $y_i \in \mathcal{Y} = \{0, 12, 24\}$ – метка класса,
- $n = 300$ – число образцов.

Цель – построить модель $F : \mathbb{R}^d \rightarrow \mathcal{Y}$, минимизирующую ожидаемую кросс-энтропию:

$$\mathcal{L}(F) = -\mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \sum_{k=1}^c \mathbb{I}(y = k) \log p_k(\mathbf{x}), \quad (15)$$

где $c = 3$, $p_k(\mathbf{x}) = P(y = k | \mathbf{x})$.

Структура модели CatBoost реализует градиентный бустинг над симметричными деревьями. Прогноз модели имеет вид:

$$F(\mathbf{x}) = \sum_{t=1}^T \eta \cdot h_t(\mathbf{x}), \quad (16)$$

где:

- $h_t : \mathbb{R}^d \rightarrow \mathbb{R}^c$ – слабый классификатор (дерево) на шаге t ,
- $\eta \in (0, 1)$ – скорость обучения,
- T – число итераций.

Функция потерь и градиенты На каждой итерации t вычисляются псевдо-остатки $\mathbf{r}_i^{(t)} \in \mathbb{R}^c$:

$$r_{i,k}^{(t)} = -\frac{\partial \mathcal{L}(y_i, F^{(t-1)}(\mathbf{x}_i))}{\partial F_k^{(t-1)}(\mathbf{x}_i)}, \quad (17)$$

где $F^{(t-1)} = \sum_{s=1}^{t-1} \eta h_s$ – текущий ансамбль. Для кросс-энтропии:

$$r_{i,k}^{(t)} = \mathbb{I}(y_i = k) - p_k^{(t-1)}(\mathbf{x}_i). \quad (18)$$

Обучение деревьев Каждое дерево h_t обучается приближать псевдо-остатки:

$$h_t = \arg \min_{h \in \mathcal{H}} \sum_{i=1}^n \sum_{k=1}^c \left(r_{i,k}^{(t)} - h_k(\mathbf{x}_i) \right)^2, \quad (19)$$

где $\mathcal{H}$ – класс симметричных деревьев с ограничением глубины L .

Симметричные деревья Каждое дерево строится жадным алгоритмом:

1. Для каждого признака j и порога τ вычисляется критерий информативности:

$$G(j, \tau) = \sum_{k=1}^c \left[\frac{(\sum_{i \in \mathcal{L}} r_{i,k})^2}{|\mathcal{L}|} + \frac{(\sum_{i \in \mathcal{R}} r_{i,k})^2}{|\mathcal{R}|} \right], \quad (20)$$

где $\mathcal{L} = \{i | x_{i,j} \leq \tau\}$, $\mathcal{R} = \mathcal{D} \setminus \mathcal{L}$.

2. Выбирается пара (j^*, τ^*) , максимизирующая $G(j, \tau)$.
3. Рекурсивно разделяются дочерние узлы.

Регуляризация в CatBoost

- **L2-регуляризация:**

$$\mathcal{R}_{\text{leaf}} = \lambda \sum_{\text{leaf}} \sum_{k=1}^c (v_{\text{leaf},k})^2, \quad (21)$$

где $v_{\text{leaf},k}$ – значение в листе для класса k .

- **Стохастический градиентный бустинг:** На каждой итерации используется подвыборка $\mathcal{D}_t \subset \mathcal{D}$ размера $\rho \cdot n$.
- **Упорядоченное бустинг:** Для борьбы со смещением при обработке категориальных признаков (в данной задаче не применяется).

Алгоритм обучения

1. Инициализация: $F^{(0)}(\mathbf{x}) = \mathbf{0}$.
2. Для $t = 1$ до T :
 - (а) Вычисление псевдо-остатков $\mathbf{r}^{(t)}$.
 - (б) Построение дерева h_t на $\mathcal{D}_t$.
 - (с) Обновление: $F^{(t)} = F^{(t-1)} + \eta h_t$.
3. Возврат $F^{(T)}$.

Гиперпараметры

- Глубина деревьев $L = 6$,
- Скорость обучения $\eta = 0.03$,
- Коэффициент L2 $\lambda = 3.0$,
- Доля подвыборки $\rho = 0.8$.

2.4. Метод снижения размерности PCA

Обоснование применения PCA Пусть $X \in \mathbb{R}^{n \times d}$ – исходная матрица данных, где:

- n – количество образцов
- d – исходная размерность признакового пространства (число спектральных каналов)
- $\mu \in \mathbb{R}^d$ – вектор выборочных средних: $\mu_j = \frac{1}{n} \sum_{i=1}^n X_{ij}$

1. **Центрирование данных** (устранение смещения):

$$\tilde{X} = X - \mu = \begin{bmatrix} X_{11} - \mu_1 & \cdots & X_{1d} - \mu_d \\ \vdots & \ddots & \vdots \\ X_{n1} - \mu_1 & \cdots & X_{nd} - \mu_d \end{bmatrix} \quad (22)$$

2. **Сингулярное разложение (SVD)**:

$$\tilde{X} = U \Sigma V^T \quad (23)$$

где:

- $U \in \mathbb{R}^{n \times n}$ – ортогональная матрица левых сингулярных векторов
- $\Sigma \in \mathbb{R}^{n \times d}$ – диагональная матрица сингулярных значений $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$ ($r = \text{rank}(\tilde{X})$)
- $V \in \mathbb{R}^{d \times d}$ – ортогональная матрица правых сингулярных векторов (главных компонент)

3. **Критерий выбора числа компонент**:

$$k = \min \left\{ m \in \mathbb{N} : \frac{\sum_{i=1}^m \sigma_i^2}{\sum_{j=1}^d \sigma_j^2} \geq 0.99 \right\} \quad (24)$$

где:

- σ_i^2 – квадраты сингулярных значений (пропорциональные дисперсии)
- Знаменатель $\sum_{j=1}^d \sigma_j^2 = \|\tilde{X}\|_F^2$ – полная дисперсия данных
- Числитель $\sum_{i=1}^m \sigma_i^2$ – дисперсия, сохраняемая первыми m компонентами

4. Проекция в подпространство:

$$Z = \tilde{X}V_{:,1:k} = \begin{bmatrix} \tilde{x}_1 \cdot v_1 & \cdots & \tilde{x}_1 \cdot v_k \\ \vdots & \ddots & \vdots \\ \tilde{x}_n \cdot v_1 & \cdots & \tilde{x}_n \cdot v_k \end{bmatrix} \in \mathbb{R}^{n \times k} \quad (25)$$

где:

- $V_{:,1:k} = [v_1|v_2|\dots|v_k]$ – матрица первых k главных компонент
- $\tilde{x}_i$ – i -я центрированная спектральная запись
- $z_{ij} = \tilde{x}_i \cdot v_j$ – проекция i -го образца на j -ю компоненту

Интерпретация:

- Сингулярные значения σ_i определяют "важность" компонент
- Главные компоненты v_i – ортонормированные направления максимальной дисперсии
- Матрица Z содержит низкоразмерное представление с сохранением 99% информации

Обоснованность подхода Применение метода главных компонент (PCA)

обусловлено:

1. **Высокой корреляцией признаков:** Соседние спектральные каналы сильно коррелируют
2. **Проклятием размерности:** $d \gg n$ требует снижения размерности
3. **Вычислительной эффективностью:** Обучение на низкоразмерном представлении

4. **Интерпретируемостью:** Выделение значимых спектральных диапазонов

Предложенная архитектура является корректной по следующим причинам:

- **Сохранение информации:** Порог 99% дисперсии гарантирует сохранение информативных компонент
- **Совместимость с регуляризацией:** Преобразование весов обратно в исходное пространство:

$$W_{\text{original}} = W_{\text{PCA}} V^T \quad (26)$$

- **Физическая интерпретация:** Анализ весов в исходном пространстве соответствует принципам спектроскопии

Модель классификации Для проекций Z строится логистическая регрессия из первой части:

$$f(z) = \text{softmax}(Wz + b) \quad (27)$$

Корректность подхода Сочетание PCA с логистической регрессией является стандартным подходом.

Ограничения:

- **Линейность PCA:** Не учитывает нелинейные зависимости
- **Фиксированный порог дисперсии:** Может требовать адаптации для других данных
- **Вычислительная сложность:** Обратное преобразование весов требует $O(dk)$ операций

Предложенная модель:

- Корректно использует PCA для снижения размерности
- Сохраняет интерпретируемость через обратное преобразование весов
- Соответствует принципам анализа спектральных данных

3 Глава 3: Математическая модель для наблюдаемых спектральных распределений

Т.к. данных для признаков крайне мало, можно попробовать смоделировать полученные диапазоны. На данных графиках посчитаны усреднённые значения спектров для образцов с разным содержанием магния в зависимости от уровня магния и времени сбора данных.

Если модель будет успешно аппроксимировать настоящие значения, то можно будет насэмплировать из нее еще данных и улучшить синтетическими данными нашу модель.

3.1. Формализованная модель

Спектр $S(\lambda)$ для каждого типа образца (Mg 0, Mg 12, Mg 24) можно представить как:

$$S(\lambda) = B(\lambda) + T(\lambda) + \sum_{i=1}^k G_i(\lambda) \quad (28)$$

где:

- λ — длина волны (400-1000 нм)




Рис. 1: Усредненные спектры образцов растений в зависимости от содержания магния и периода сбора данных

- $B(\lambda)$ — базовая составляющая спектра
- $T(\lambda)$ — переходная функция (скачок около 700-750 нм)
- $G_i(\lambda)$ — локальные особенности спектра на специфических длинах волн

Компоненты модели:

1. Базовая составляющая:

$$B(\lambda) = b_0 + b_1\lambda + b_2\lambda^2 \quad (29)$$

Полином низкой степени для моделирования общего тренда.

2. Переходная функция (для резкого подъема около 700-750 нм):

$$T(\lambda) = \frac{A}{1 + e^{-s(\lambda-\lambda_0)}} \quad (30)$$

Где A — амплитуда перехода, s — крутизна, λ_0 — центр перехода.

3. Локальные особенности:

$$G_i(\lambda) = A_i \exp\left(-\frac{(\lambda - \mu_i)^2}{2\sigma_i^2}\right) \quad (31)$$

Гауссовы компоненты с параметрами:

- A_i — амплитуда
- μ_i — центральная длина волны
- σ_i — ширина пика

3.2. Особенности для разных типов образцов

Для учета различий между типами образцов (Mg 0, Mg 12, Mg 24):

1. Параметры базовой составляющей b_j зависят от концентрации Mg.
2. Около 10 специфических длин волн имеют различные параметры G_i для каждого типа образца.
3. Наиболее заметные различия наблюдаются в диапазоне 750-950 нм, где параметры A_i и, возможно, μ_i зависят от концентрации Mg.

3.3. Полная модель

$$S_{\text{Mg,период}}(\lambda) = B_{\text{Mg}}(\lambda) + T_{\text{Mg}}(\lambda) + \sum_{i=1}^{n_{\text{общий}}} G_i(\lambda) + \sum_{j=1}^{10} G_{j,\text{Mg,период}}(\lambda) \quad (32)$$

где индексы Mg и “период” указывают на зависимость параметров от концентрации магния и периода измерения.

Такая модель объясняет как общую структуру спектров, так и специфические различия между образцами и периодами измерений.

3.4. Практическая реализация




Рис. 2: Пример аппроксимации реальных спектров разработанной моделью

Для реализации построенной модели написан код, который можно найти в репозитории [25]. Я использовал язык python, и все библиотеки из первой главы.

4 Глава 4. Результаты.

В данной главе представлены результаты обучения и оценки трех моделей машинного обучения.

4.1. Результаты логистической регрессии.

Логистическая регрессия обучалась с двумя кастомными регуляризациями, и их код можно найти в этом репозитории. До интерпретации результатов важно учесть, что регуляризации вводились и для того чтобы понять самые важные, значимые диапазоны. Поэтому итоговая точность меньше, чем могла бы быть, зато это позволит в дальнейшем сфокусироваться только на спектрах, где есть различие.




Рис. 3: Матрица ошибок для логистической регрессии на тестовой выборке

Результаты на тестовой выборке

Результаты экспериментов

Метрики качества на тестовой выборке

- **Точность (Accuracy):** 0.4833 (48.33%)
- **Precision (Точность):** 0.4725
- **Recall (Полнота):** 0.4833

Таблица 1: Отчет по классификации для логистической регрессии

Класс	Precision	Recall	F1-score	Support
0	0.46	0.60	0.52	20
12	0.38	0.25	0.30	20
24	0.57	0.60	0.59	20
Accuracy	0.4833			
Macro avg	0.47	0.48	0.47	60
Weighted avg	0.47	0.48	0.47	60

Значимые спектральные диапазоны Выявлены информативные диапазоны длин волн для разных классов:

- **Mg 12:**
 - 963.6-968.1 нм (ширина 4.5 нм)
- **Mg 24:**
 - 925.6-936.8 нм (11.1 нм)
 - 972.6-979.3 нм (6.7 нм)
 - 992.8-1004.1 нм (11.3 нм)
 - 1029.0-1031.2 нм (2.3 нм)




Рис. 4:

Интерпретация и анализ обучения логистической регрессии

В результате получился классификатор, лучше случайного, но пока не подходящий для реальной работы. Зато при различных видах обучения не нулевые коэффициенты были сосредоточены в областях длинных >900 волн. Соответственно, в дальнейшем при анализе следует сосредоточить внимание на этих волнах.

Так же, к сожалению, классификатор магния 12 выдает худшие результаты. Это связано с его близостью к другим классам. В дальнейшем имеет смысл сосредоточить внимание на бинарной классификации хватает или не хватает магния. Если $\text{Assurasy mg } 0 = 1$, то это позволит точно находить все зоны с 0 магния и не дополнять там где не нужно.




Рис. 5:




Рис. 6:

4.2. Градиентный бустинг

В рамках исследования проведено сравнительное тестирование трех наиболее распространенных реализаций градиентного бустинга: XGBoost, LightGBM и CatBoost. Наибольшую эффективность продемонстрировал алгоритм CatBoost, что определило его выбор для последующего анализа.

Реализация обучения осуществлялась с использованием специализированной библиотеки CatBoost. После первичного обучения выполнена оптимизация гиперпараметров методом сеточного поиска с последующей кросс-валидацией на тестовой выборке.

Таблица 2: Classification Report

Класс	Precision	Recall	F1-score	Support
0	0.41	0.80	0.54	20
12	0.33	0.15	0.21	20
24	0.75	0.45	0.56	20
Accuracy	0.47			
Macro avg	0.50	0.47	0.44	60
Weighted avg	0.50	0.47	0.44	60

Результаты Однако анализ результатов кросс-валидации демонстрирует улучшение метрики точности (Рис. 3), что свидетельствует о повышении обобщающей способности модели.

Исследование значимости признаков (Рис. 9) выявило ключевые спектральные диапазоны, оказывающие максимальное влияние на прогноз модели:




Рис. 7: Матрица ошибок




Рис. 8: Точность на всем наборе данных

Выводы Применение градиентного бустинга позволило достичь сопоставимых показателей точности с предыдущими методами при сохранении согласованности в определении значимых спектральных диапазонов.




Рис. 9: Точность на всем наборе данных

Наибольший вклад в прогноз вносят:

- 392.1 нм: 3.2298
- 999.6 нм: 2.6455
- 997.3 нм: 2.2515
- 1022.2 нм: 1.8960

Доминирование признаков в диапазоне 900-1000 нм подтверждает их диагностическую ценность, тогда как аномалия на 392 нм может указывать на наличие шумового компонента. Для верификации гипотезы целесообразно провести дополнительное исследование с ограничением признакового пространства указанным диапазоном.

4.3. PCA

Код и результаты Реализация алгоритма обучения представлена в открытом репозитории [25], архитектура модели дополнительно визуализи-

зирована в приложении в виде блок-схемы.

Анализ значимых признаков (Рис. 10) демонстрирует, что 21 отобранный признак обеспечивает объяснение 99% дисперсии данных, что свидетельствует о выраженной ковариации между волновыми параметрами. Данный факт подтверждает гипотезу о наличии структурной избыточности в исходном признаковом пространстве.




Рис. 10: График объясненной дисперсии в зависимости от числа главных компонент (PCA)

Сравнительный анализ эффективности модели (Табл. 3) выявил незначительное улучшение метрик относительно базовой логистической регрессии. Общая точность классификации составила 0.50 при макро-усредненных значениях $\text{Precision}=0.49$ и $\text{Recall}=0.50$, что указывает на сохранение проблем с дифференциацией среднего диапазона, что дополнительно подтверждается анализом матрицы ошибок (Рис. 11).

Исследование коэффициентов реконструированной логистической ре-

Таблица 3: Отчет по классификации для логистической регрессии после снижения размерности методом PCA

Класс	Precision	Recall	F1-score	Support
0	0.46	0.60	0.52	20
12	0.45	0.25	0.32	20
24	0.57	0.65	0.60	20
Accuracy	0.50			
Macro avg	0.49	0.50	0.48	60
Weighted avg	0.49	0.50	0.48	60

грессии (Рис. 3) выявило согласованность с результатами CatBoost и исходной регрессионной моделью. Наблюдаются устойчивые кластеры значимых длин волн:




Рис. 11: Матрица ошибок для логистической регрессии после PCA на тестовой выборке

Совпадение диагностически значимых диапазонов в независимых моделях подтверждает устойчивость выявленных спектральных маркеров и обоснованность применения методов линейной параметризации.




Рис. 12: Веса логистической регрессии после PCA, спроецированные в исходное пространство спектральных признаков

- Mg 0: 936.8-939.0 нм (2.2 нм), 959.1-1006.4 нм (47.2 нм), 1026.7-1031.2 нм (4.5 нм)
- Mg 12: 392.1-394.1 нм (2.0 нм), 414.4-420.5 нм (6.1 нм)
- Mg 24: 983.8-1008.6 нм (24.8 нм), 1026.7-1031.2 нм (4.5 нм)

Выводы Применение методов уменьшения размерности способствует незначительному повышению точности модели. Проведенный анализ методом главных компонент (PCA) демонстрирует наличие выраженных корреляционных взаимосвязей между исследуемыми переменными. Данное наблюдение, вероятно, обусловлено тем, что для объектов со схожими характеристиками (например, волновыми параметрами) значения измерений демонстрируют предсказуемость, основанную на простран-

ственной близости соответствующих наблюдений в признаковом пространстве.

Полученные результаты также подтверждают обоснованность ключевой предпосылки логистической регрессии, предполагающей, что объекты со сходными свойствами вносят сопоставимый вклад в формирование прогноза модели. Это согласуется с выявленной структурой данных, где высокая корреляция между признаками отражает существование латентных закономерностей, допускающих компактное параметрическое представление.

Заключение

1. Изучены и проанализированы:

- Биологическая роль магния в растениях пшеницы и его влияние на спектральные характеристики отражения, в частности через содержание хлорофилла и структуру тканей.
- Существующие методы определения содержания магния: традиционные химические (ААС, ИСП-МС) с их ограничениями (трудоемкость, разрушающий характер) и современные спектральные подходы (спектроскопия отражения VIS/NIR/SWIR).
- Методы машинного обучения, применимые для анализа гиперспектральных данных: логистическая регрессия, методы регуляризации (включая специфичные для спектральных данных), ансамблевые методы (градиентный бустинг), методы снижения размерности (РСА).

- Теоретические основы взаимосвязи спектральных данных и биохимического состава растений.

2. **Подготовлен и предобработан набор данных:** Использовались экспериментальные данные, включающие спектральные измерения (~ 300 длин волн в диапазоне 390–1031 нм) для образцов пшеницы с тремя уровнями содержания магния (mg0, mg12, mg24). Выполнена стандартизация данных для корректной работы моделей.

3. **Разработаны и обучены модели машинного обучения:**

- Реализована модель **логистической регрессии** с применением **кастомных физически обоснованных регуляризаций**: регуляризации гладкости (штрафующей резкие изменения весов соседних длин волн) и групповой регуляризации (штрафующей совместную активацию удаленных длин волн). Это позволило не только классифицировать образцы, но и интерпретировать вклад различных участков спектра.
- Применена модель **градиентного бустинга (CatBoost)**, показавшая свою эффективность на табличных данных, и проведена оптимизация её гиперпараметров.
- Исследован подход с **предварительным снижением размерности** данных с помощью метода главных компонент (PCA), сохранившего 99% дисперсии в 21 компоненте, с последующим обучением логистической регрессии на новом признаковом пространстве.
- Предложена и частично апробирована **математическая модель** для аппроксимации наблюдаемых спектральных кривых

с целью лучшего понимания структуры данных и потенциальной генерации синтетических данных в будущем.

4. Проведено тестирование и сравнение моделей:

- Модели протестированы на отложенной выборке с использованием метрик Accuracy, Precision, Recall, F1-score и анализа матриц ошибок. Достигнутая точность классификации составила около 47–50%, что указывает на сложность задачи и/или необходимость большего объема данных.
- Все модели показали трудности с надежной классификацией промежуточного класса (mg12), который часто путался с крайними классами.
- Анализ весов логистической регрессии (с регуляризациями и после PCA) и значимости признаков в CatBoost выявил **консистентные информативные спектральные диапазоны**, преимущественно в ближней инфракрасной области (> 900 нм), в частности, участки около 925–940 нм, 960–1010 нм и 1025–1031 нм оказались значимыми для различения классов. Отмечена также потенциальная значимость отдельных коротковолновых участков (например, выраженный пик около 392 нм в CatBoost).

5. Сделаны выводы о практической применимости:

- Работа демонстрирует принципиальную возможность использования гиперспектральных данных и машинного обучения для оценки содержания магния в пшенице, однако достигнутая точность пока недостаточна для надежного практического применения в виде трехклассовой задачи.

- Выявленные информативные диапазоны (> 900 нм) могут быть использованы для разработки более простых и дешевых сенсоров или для фокусировки дальнейших исследований.
- Результаты указывают на перспективность дальнейшей работы, возможно, с использованием большего объема данных, данных временных рядов наблюдений, фокусировки на бинарной задаче (дефицит/достаток) или применения более сложных моделей (например, глубокого обучения) и методов борьбы с шумом.


Список литературы

1. *Blackburn G. A.* Spectral indices for estimating photosynthetic pigment concentrations: a test using senescent tree leaves // International Journal of Remote Sensing. — 1998. — Т. 19, № 4. — С. 657—675.
2. *Breiman L.* Random forests // Machine learning. — 2001. — Т. 45, № 1. — С. 5—32.
3. CatBoost: unbiased boosting with categorical features / L. Prokhorenkova [и др.] // Advances in neural information processing systems. Т. 31. — 2018.
4. Characterizing canopy biochemistry from imaging spectroscopy and its relation to ecosystem services / R. F. Kokaly [и др.] // Remote Sensing of Environment. — 2009. — Т. 113. — С. 78—91.
5. *Curran P. J.* Remote sensing of foliar chemistry // Remote Sensing of Environment. — 1989. — Т. 30, № 3. — С. 271—278.
6. Deep learning classifiers for hyperspectral imaging: A review / M. E. Paoletti [и др.] // ISPRS Journal of Photogrammetry and Remote Sensing. — 2019. — Т. 158. — С. 279—317.
7. Detection of phosphorus and nitrogen deficiencies in corn using spectral radiance measurements / S. L. Osborne [и др.] // Agronomy Journal. — 2002. — Т. 94, № 6. — С. 1215—1221.
8. *Ferwerda J. G., Skidmore A. K.* Can nutrient status of four woody plant species be predicted using field spectrometry data? // ISPRS journal of photogrammetry and remote sensing. — 2005. — Т. 60, № 1. — С. 34—42.
9. *Friedman J. H.* Greedy function approximation: a gradient boosting machine // Annals of statistics. — 2001. — С. 1189—1232.
10. *Gitelson A. A., Gritz Y., Merzlyak M. N.* Relationships between leaf chlorophyll content and spectral reflectance and algorithms for non-destructive chlorophyll assessment in higher plant leaves // Journal of Plant Physiology. — 2003. — Т. 160, № 3. — С. 271—282.
11. *Grechuk B., Sidorov D., Zolotikh N.* Optimal linear dimension reduction for logistic regression. — 2020. — arXiv: 2005.07764 [stat.ML]. — URL: <https://arxiv.org/abs/2005.07764> (дата обр. 13.05.2025).

12. Handbook of reference methods for plant analysis / под ред. Y. P. Kalra. — CRC press, 1998.
13. Hyperspectral vegetation indices and novel algorithms for predicting green LAI of crop canopies: Modeling and validation in the context of precision agriculture / D. Haboudane [и др.] // Remote Sensing of Environment. — 2004. — Т. 90, № 3. — С. 337—352.
14. *Jones Jr J. B.* Laboratory guide for conducting soil tests and plant analysis. — CRC press, 2001.
15. *Mahlein A.-K.* Plant disease detection by imaging sensors—parallels and specific demands for precision agriculture and plant phenotyping // Plant disease. — 2016. — Т. 100, № 2. — С. 241—251.
16. Marschner's Mineral Nutrition of Higher Plants / под ред. P. Marschner. — Third. — Academic Press, 2012.
17. Methods of Soil Analysis: Part 3 Chemical Methods / под ред. D. L. Sparks. — Soil Science Society of America, Inc., 1996. — (SSSA Book Series No. 5).
18. *Mulla D. J.* Twenty five years of remote sensing in precision agriculture: Key advances and remaining knowledge gaps // Biosystems engineering. — 2013. — Т. 114, № 4. — С. 358—371.
19. Plant Physiology and Development / L. Taiz [и др.]. — Sixth. — Sunderland, MA : Sinauer Associates, Inc., 2015.
20. *Sidorov D., Zolotykh N.* On the Fisher separability of random points in the n-cube. — 2020. — arXiv: 2004.01156 [math.CO]. — URL: <https://arxiv.org/abs/2004.01156> (дата обр. 13.05.2025).
21. *Sims D. A., Gamon J. A.* Relationships between leaf pigment content and spectral reflectance across a wide range of species, leaf structures and developmental stages // Remote sensing of Environment. — 2002. — Т. 81, № 2/3. — С. 337—354.
22. *Thenkabail P. S., Smith R. B., De Pauw E.* Hyperspectral vegetation indices and their relationships with agricultural crop characteristics // Remote sensing of Environment. — 2000. — Т. 71, № 2. — С. 158—182.

23. *Tibshirani R.* Regression shrinkage and selection via the lasso // Journal of the Royal Statistical Society: Series B (Methodological). — 1996. — Т. 58, № 1. — С. 267—288.
24. Using imaging spectroscopy to study ecosystem processes and properties / S. L. Ustin [и др.] // BioScience. — 2004. — Т. 54, № 6. — С. 523—534.
25. *Николай К.* Код для вкр. — 2025. — URL: <https://github.com/Kol2ja/diplom> (дата обр. 13.05.2025).

Приложения



Примечание: Все этапы инкапсулированы
в классе GradientBoostingAnalysis. Основ-
ной поток выполнения контролируется
методом main()

Рис. 13: Блок-схема алгоритма обучения градиентного бустинга

